

销售数据清洗报告

销售数据清洗报告

本报告由 **data-cleaning skill (Agent + R tidyverse)** 生成。

流水线：概览诊断 → 逐项清洗（代码/结果/说明） → 整洁数据 → 总结。

数据来源：原始数据（`raw` 只读，所有改动作用在 `clean` 副本上完成）。

概览 · 一屏看懂

数据信息

源	清洗前	清洗后	输出
<code>messy_sales.csv</code>	43 行×5 列	43 行×5 列	<code>output/messy_sales_cleaned.csv</code>

脏在哪 · 诊断总表

#	脏在哪	位置/样例	规模	处置
1	缺失	Revenue(CNY) 2 处、Store 1 处	3	保留 NA，报告不盲填
2	完全重复行	订单 1001/1016/1030 各录入两次	3	<code>distinct()</code> 删除
3	主键重复	去重后 <code>order_id</code> 无重复	0	—
4	负值	订单 1013 收入 -120	1	打标 <code>revenue_negative</code>
5	离群值	99999 与 2058 (IQR 1.5×)	2	打标 <code>revenue_outlier_flag</code>
6	类别混杂	Online/online/ONLINE/线上/...	8	<code>case_when()</code> 归并为 2 类
7	日期多格式	Y/m/d、Y-m-d、Ymd	3	<code>parse_date_time()</code> 统一
8	非数值收入	¥1,234、¥2,058 带货币符号	2	<code>parse_number()</code> 解析
9	列名不规范	Order ID、Revenue(CNY)	2	<code>make_clean_names()</code>


主线：先看懂「脏在哪」，再逐项清洗并保留证据（异常打标），最后交付整洁数据 + 前后对照总结。

1. 脏数据诊断（自动，不改数据）

```
miss_tbl = data.frame(  
  字段 = names(raw),  
  缺失 = unname(miss_cnt(raw))  
) |>  
  arrange(desc(缺失))  
  
miss_tbl |>  
  filter(缺失 > 0) |>  
  knitr::kable(format = "pipe", caption = "缺失 / 空白")
```

字段	缺失
Revenue(CNY)	2
Store	1

```
miss_tbl |>
  filter(缺失 > 0) |>
  ggplot(aes(x = reorder(字段, 缺失), y = 缺失)) +
    geom_col(fill = "#c0392b") +
    coord_flip() +
    labs(x = NULL, y = "缺失 / 空白数")
```



类别列有 8 种写法、日期列 3 种格式、收入列混入带 ¥ 的文本——均见 §2 逐项处理。

2. 逐项清洗（代码 + 结果 + 说明）

2.1 列名 → snake_case

```
clean = clean |>
  rename_with(~(x) janitor::make_clean_names(x, case = "snake"))
```

说明：Order ID → order_id、Revenue(CNY) → revenue_cny，为程式访问铺路。

2.2 完全重复行

```
n0 = nrow(clean)
clean = clean |> distinct()
```

结果：43 行 → 40 行（删除 3 行全同记录）。订单 1001/1016/1030 各被录入了两次，属完全重复，按默认决策表可直接删除并记录数量。

2.3 日期多格式统一（保留原列 + 失败 flag）

```
clean = clean |>
  mutate(
    sale_date_raw = sale_date,
    sale_date = suppressWarnings(
      lubridate::parse_date_time(
        sale_date_raw,
        orders = c("Y/m/d", "Y-m-d", "Ymd"),
        quiet = TRUE
```

```

) |>
  as.Date(),
  date_parse_fail = is.na(sale_date) & !is.na(sale_date_raw)
)

```

结果：40 行解析成功，失败 0 行。

说明：三种格式一次给出；**保留原列** `sale_date_raw`，新增解析列与失败 flag，不覆盖原字段。

2.4 收入文本解析（货币符号 + 千分位）

```

clean = clean |>
  mutate(
    revenue_raw = as.character(revenue_cny),
    revenue_num = readr::parse_number(revenue_raw),
    revenue_parse_fail = is.na(revenue_num) & !is.na(revenue_raw)
  )

```

结果：¥1,234、¥2,058 两行文本收入解析为数值，原列保留为 `revenue_raw`。

说明：`readr` 的 locale 猜型会把纯千分位 "1,234" 自动转成数值（见 SKILL.md 坑表），但带货币符号 ¥ 时列保持文本，需显式 `parse_number()`——这正是「数值含单位/货币」默认决策行覆盖的情形。

2.5 类别归并（不用 TRUE 默认分支）

```

clean = clean |>
  mutate(category_norm = case_when(
    str_detect(str_to_lower(str_squish(category)), "^on") ~ "线上",
    str_detect(str_to_lower(str_squish(category)), "^off") ~ "线下",
    str_squish(category) == "线上" ~ "线上",
    str_squish(category) == "线下" ~ "线下"
  ))

```

结果：

```

clean |>
  count(category_norm) |>
  knitr::kable(format = "pipe", caption = "归并后渠道类别")

```

category_norm	n
线上	25
线下	15

说明：8 种写法归并为 2 类；**故意不写 TRUE ~ 默认值 分支**，未匹配的会得 NA 并被统计（本例 0 行），避免 `case_when` 默认分支静默吞 NA 的经典陷阱。

2.6 异常打标（只标不删）

```

q = quantile(clean$revenue_num, c(0.25, 0.75), na.rm = TRUE)
iqr = IQR(clean$revenue_num, na.rm = TRUE)

clean = clean |>
  mutate(
    revenue_negative = !is.na(revenue_num) & revenue_num < 0,
    revenue_outlier_flag = !is.na(revenue_num) &
      (revenue_num < q[[1]] - 1.5 * iqr |

```

```
revenue_num > q[[2]] + 1.5 * iqr)
)
```

结果：负值 1 行（订单 1013 的 -120），离群 2 行（99999 与 2058）。

说明：异常值默认打标不删除，原值保留供复核；删除/截尾必须说明规则并经用户确认。

3. 整洁数据

```
clean |>
  select(order_id, store, sale_date, revenue_num, category_norm,
         revenue_negative, revenue_outlier_flag) |>
  head(8) |>
  knitr::kable(format = "pipe", caption = "清洗后前 8 行 (关键列)")
```

order_id	store	sale_date	revenue_num	category_norm	revenue_negative	revenue_outlier_flag
1001	朝阳店	2023-01-05	856	线上	FALSE	FALSE
1002	朝阳店	2023-01-09	432	线上	FALSE	FALSE
1003	海淀店	2023-01-15	1280	线下	FALSE	FALSE
1004	海淀店	2023-01-18	1234	线下	FALSE	FALSE
1005	西城店	2023-01-20	977	线上	FALSE	FALSE
1006	西城店	2023-02-01	NA	线上	FALSE	FALSE
1007	朝阳店	2023-02-03	1105	线下	FALSE	FALSE
1008	NA	2023-02-08	689	线下	FALSE	FALSE

4. 清洗总结（前后对照 + 日志）

指标	清洗前	清洗后
行数	43	40
列数	5	13
缺失单元格	3	7

清洗后缺失单元格多出的 4 处来自「保留原列」策略的镜像缺失（`revenue_raw/revenue_num` 与 `revenue_cny` 对应同样 2 行），真实缺失仍为 3 处，未做任何填补——是否填补属业务决策，见「遗留」。

做了什么（一句话清单）

- 审计出 9 类脏：缺失、重复、负值、离群、类别混杂、日期多格式、非数值收入、列名不规范
- 清洗顺序：列名 → 去重 → 日期 → 收入 → 类别 → 异常打标
- 原则：异常只打标、缺失不盲填、原始不覆盖、每步留证据

数据字典 / 日志 / 遗留

- **数据字典**：新增列 `sale_date_raw/sale_date/date_parse_fail`、`revenue_raw/revenue_num/revenue_parse_fail`、`category_norm`、`revenue_negative/revenue_outlier_flag`；完整口径见清洗日志
- **清洗日志**：`output/cleaning_log.csv`（7步，每步含规则、前后行数、影响、决策类型）
- **遗留**：3处缺失是否填补待业务确认；负值与离群行的复核与处置；类别词典（线上/线下）如需扩展须同步 `case_when` 映射